贝叶斯与神经网络的和解之路

https://gemini.google.com/app/c183dbe39550c9bc

User prompt: 贝叶斯与神经网络的"世纪和解"：一个两阶段配方，让人工智能更懂人的认知 认知科学里有一场延续了数十年的范式之争：要理解人类心智，到底该用贝叶斯模型——强调符号化规则与强先验的自上而下路线；还是神经网络（联结主义）——强调从简单计算单元中涌现表征的自下而上路线。两条路线各有拥趸，也各有绕不开的短板。 普林斯顿大学与麻省理工学院的研究者近日在 arXiv 上发布了一项新工作，给出了一种"和解方案"。他们提出的 BBT （ Bayesian distillation with Behavioral Tuning ，贝叶斯蒸馏＋行为微调），用一套简单的两阶段配方，让一个约 3000 万参数的 Transformer 同时获得两大范式的优势，并在四个经典概念学习任务上，对人类行为的预测全面优于纯贝叶斯模型和纯神经网络。 一场持续半个世纪的范式之争 这场争论的根源，在于两大传统对"心智"的两种不同看法。 贝叶斯传统遵循马尔的"计算层面"分析，是一种自上而下的路径：研究者先把问题刻画为计算问题与理想解，把假设形式化为结构化表征（规则、文法、程序等），把先验看作假设上的概率信念，把学习看作对这些信念的贝叶斯更新。它的优势明显：能灵活地检验人可能携带的各种先验知识与表征类型（规则、程序、向量空间），并且凭借更丰富的先验，具备从一两个例子就学会新概念的能力。 联结主义传统则是自下而上的涌现路径：构造由简单、交互的处理单元组成的系统，研究通过连接权重学习而涌现出的表征与行为。它的假设更一般、更少人为设定，能灵活逼近自然数据的复杂度，恰好弥补贝叶斯模型容易"过度简化"的毛病——后者无论是假设的符号化表征，还是先验中的参数化、独立性假设，都可能只是真实世界结构的一阶近似。 两者在计算成本上也走向相反方向：贝叶斯模型做一次预测常常要在巨大的假设空间上求和（往往不可解，只能粗近似）；神经网络训练昂贵，但一旦训练完成，预测只需一次快速前向传播。 研究者需要经常在两者之间"二选一"：想要强先验与可解释，就得忍受贝叶斯模型的简化与高昂推理；想要灵活与高效推理，就得接受神经网络的"数据饥渴"与黑箱。 BBT 想打破这种取舍。 BBT 的两步配方：先蒸馏，再微调 BBT 的思路很直白，分两步走。 第一步，蒸馏。 建模者先用成熟的贝叶斯工具，把想检验的先验知识或归纳偏置指定为一个贝叶斯模型；然后通过前向采样（从先验采样假设、再由似然生成输入输出对）产生大量合成数据，训练一个 Transformer 去逼近该贝叶斯模型的后验预测分布。关键在于：这一步不需要做贝叶斯推理，只需从模型里"抽数据"。训练后的网络在推理时权重冻结，新任务的学习完全靠前向传播实现，本质上是一种基于记忆的元学习。 第二步，行为微调。 蒸馏得到的网络还不是成品。研究者在人类行为数据上对网络进行微调，捕捉额外结构。这一步不再受原贝叶斯先验、似然甚至贝叶斯推理逻辑的约束——只要人类行为支持， BBT 可以改变假设上的先验、改变假设与数据的关系，甚至引入无法用简单符号描述的新假设。 用论文中的频谱图来说：贝叶斯范式在"强先验、符号化、参数化"一端，联结主义在"弱先验、亚符号化、非参数化"另一端； BBT 从贝叶斯端出发，经微调后按数据质量自适应地停在中间某个位置。需要说明的是，作者强调这是一种模型拟合流程，而非关于认知发展的主张。 四个案例：预测人类行为全面领先 论文在四个跨度很大的概念学习任务上验证了 BBT ，且四个任务共用同一套 3000 万参数架构。 数字概念学习（ Tenenbaum 数字游戏）。给定一组神秘程序生成的数字，判断某个新数字是否也会被生成。在这类任务上， BBT 对人类"是/否"判断的预测相关达到 r=0.81 （ RMSE=0.153 ），显著优于经典贝叶斯模型（r=0.66）；在留出数据上的对数似然领先 3175 个自然对数

点。对照组显示，只微调不蒸馏的网络表现最差。这说明贝叶斯蒸馏这一"先验注入"步骤是关键。 逻辑概念学习（ Piantadosi 等人 108 个概念）。 BBT 优于原研究考察的全部 21 个贝叶斯模型，对数似然至少领先 7826 个自然对数点，预测相关 r=0.88 ，并且对微调时从未见过的概念仍保持泛化能力。 Shepard 概念学习。这项经典任务考察逐块学习的记忆与归纳。 BBT 不仅复现了人类的学习轨迹（与人类判断相关 r=0.938），还刻画出了年龄差异：模拟年轻成人的正确率为 86.9%、老年 77.7%，对应真实人类数据中的 78.6% 与 65.9%。进一步地，把在一个研究上微调好的模型拿来预测六年后、不同实验范式的另一项研究行为，仍能保持接近的水平，展示了跨研究泛化能力。 组合式指令学习（ Lake & Baroni 的元学习任务）。人类学会一组伪语言的输入输出规则后，需要组合泛化到新指令。当人类犯错时，会呈现出两种系统性偏置：一对一映射偏置（占人类错误的 24.4%）与图标拼接偏置（ 23.3%）。 BBT 无需手工设计就学会了这些偏置，甚至在对数似然上（-343.6 ）略优于此前手工注入偏置的模型（-349.2 ）。 比预测更重要的发现：人脑可能"偏爱简单"🤓 BBT 的价值不止于更准的预测。通过对比微调前后的内部表征，研究者发现了一个贯穿四个任务的规律：微调后，模型系统性转向更简单的假设。 数字任务中，"偶数/奇数""以某数字结尾"这类数学上更简单的规则影响力大幅上升，而"幂""倍数"等复杂规则减弱；逻辑任务中，带量词的复杂规则让位于简单规则乃至常数； Shepard 任务里，基于单特征的 Type I 规则占比上升——且年轻人比老年人更快转向这种简单策略。 这提示了一个心理学上的解释：人类的行为可能系统性地偏离理想贝叶斯推断，向"简单启发式"倾斜。这是单纯的贝叶斯模型看不到、也难以解释的。 与 LLM 路线对比：可解释性换范围 一个自然的追问是：如今大语言模型（ LLM ）也能直接建模人类行为，何必还要专门训练一个小模型？论文也正面回应了这个问题。以微调 LLM 建模认知的代表性工作 Centaur 为例：它的优势是单一模型可覆盖多任务、自带海量背景知识；但代价是预训练数据不受控、成功来源难以解释，甚至被批评为在人类反应序列上"走了捷径"。 BBT 的训练流程完全受控，因而能回答"模型为什么预测得好、它如何偏离了理想贝叶斯表征"这类问题。代价是模型覆盖范围更窄，且必须先从指定一个贝叶斯模型开始。 研究者也坦承了方法的局限：解释性分析依赖对可视化层与变量的选择；其稀疏分解技术限于原贝叶斯模型的假设空间，可能遗漏真正刻画人类行为的新假设；蒸馏所用的贝叶斯模型选择也会影响结果。未来方向包括：蒸馏多个竞争贝叶斯模型后再比较、将两阶段配方推广到强化学习等其他建模传统、以及用自动解释方法发现新符号假设并反哺贝叶斯假设空间。 范式之争未必非要分出胜负。 BBT 展示了一种更具建设性的可能：让神经网络先"继承"贝叶斯先验，再用真实行为数据去修正它——不仅预测得更准，还顺带暴露了人类心智一个耐人寻味的习惯：它好像，真的偏爱简单。 论文： More accurate behavioral predictions with hybrid Bayesian-connectionist models ， Brenden M. Lake （普林斯顿大学）、 Akshay K. Jagadish （普林斯顿 AI Lab ）、 Guangyuan Jiang （ MIT ）， arXiv:2608.22154 看不懂，可以解释下吗

Response: 这篇论文的核心，是提出了一种极其巧妙的模型训练流水线（Pipeline），把传统规则算法的“强逻辑”和深度学习的“高效率”结合了起来，用来更精准地模拟**人类到底是怎么学习和思考的**。

要看懂这项研究，我们可以直接把它映射为你熟悉的“预训练 + 微调”范式。

第一层背景：认知科学界的路线之争 在研究人类心智时，学术界一直有两派：

- **贝叶斯派（自上而下）：** 类似于传统的专家系统或概率图模型。优势是自带强先验规则（知道世界的运转逻辑），给一两个样本就能“举一反三”，且极具可解释性。但缺点是推理时的计算成本极高（经常需要在庞大的假设空间里做采样寻优），且真实世界太复杂，人为设定的规则往往会失效。

- **联结主义（自下而上）：** 也就是咱们熟悉的神经网络/深度学习路线。优势是极度灵活，推理极快（一次前向传播即可）。缺点是典型的“黑盒”且极度依赖海量数据，很难把人类的先验常识显式地塞进去。

第二层核心：BBT 的两阶段配方 研究者为了打破“要逻辑就慢，要快就黑盒”的困境，用一个 3000 万参数的 Transformer 跑通了两个步骤：

1. **贝叶斯蒸馏（合成数据预训练）：** 他们没有让模型在推理时去算复杂的贝叶斯概率，而是把写好的贝叶斯模型当成一个**合成数据生成器**。通过前向采样造出大量的输入输出对，然后拿这些合成数据去从头训练这个 Transformer。
    - *通俗理解：* 这相当于用一套完美的规则引擎生成了海量的教科书数据，让神经网络去硬背。学成之后，网络权重里就融入了贝叶斯的逻辑，以后面对新任务，只需要做一次极快的网络前向传播，绕开了原本高昂的计算成本。
2. **行为微调（真实数据 SFT）：** 贝叶斯模型生成的逻辑太“完美”了，但真实的人类思考往往带着偏见，喜欢走捷径。所以研究者将第一步得到的模型，在真实的人类行为测试集上进行微调。
    - *通俗理解：* 打破原来死板的规则，让模型通过真实数据去拟合人类实际的决策习惯（类似强化学习中的人类反馈微调机制）。

第三层发现：机器揭示了人类的“懒惰” 这个小参数模型在四个经典概念学习任务上，预测人类行为的准确率彻底碾压了纯贝叶斯和纯神经网络。通过对比微调前后的网络特征变化，研究者发现了一个极其有趣的现象：

微调后的模型，系统性地抛弃了那些复杂的数学假设（比如“幂”或“倍数”），转向了最基础的判断（比如看“奇数偶数”或者单纯看单个特征）。这说明**人类大脑根本不是一台完美的贝叶斯推断机，在面对复杂问题时，人类会本能地退化使用“简单的启发式规则”来凑合应对。**

为什么不直接用 LLM？ 既然是要预测人类行为，为什么不直接拿参数量巨大的大语言模型（LLM）来跑？论文作者指出，像 LLM 那种用全网无监督数据训练出来的巨型黑盒，虽然也能表现出类似人类的反应，但你根本不知道它是真的懂了认知逻辑，还是单纯在训练数据里“背”过类似的题目（数据污染）。

而 BBT 这种“指定规则生成数据 -> 训练小模型 -> 微调”的白盒受控流程，能让研究人员清清楚楚地扒开网络，看到它到底在哪一步为了迎合人类而放弃了复杂逻辑，这是庞大的黑盒 LLM 做不到的。
